LAPORAN ANALISIS SISTEM CERDAS
DETEKSI DINI RISIKO STUNTING PADA BALITA

Perbandingan Metode Fuzzy Inference System (FIS) Mamdani, Sistem Pakar Forward Chaining, dan Machine Learning XGBoost

Disusun Oleh:
Tito Dwi Saputro
2411007

PRODI INFORMATIKA / ILMU KOMPUTER
UNIVERSITAS PGRI JOMBANG
2024

BAB I: PENDAHULUAN

1.1 Latar Belakang Masalah

Stunting merupakan salah satu masalah gizi kronis terbesar yang dihadapi balita di Indonesia. Kondisi ini disebabkan oleh kurangnya asupan gizi dalam waktu lama serta infeksi berulang yang ditandai dengan panjang atau tinggi badannya berada di bawah standar. Deteksi dini sangat penting dilakukan guna mencegah dampak permanen pada perkembangan fisik dan kognitif anak.

Dengan kemajuan teknologi informasi, pendekatan Sistem Cerdas dapat digunakan untuk mengotomatisasi klasifikasi risiko ini. Laporan ini disusun untuk mengevaluasi dan membandingkan tiga pendekatan berbeda, yaitu metode konvensional berbasis aturan (Fuzzy Inference System Mamdani dan Sistem Pakar Forward Chaining) dengan model berbasis data Machine Learning (XGBoost Classifier).

1.2 Rumusan Masalah

1. Bagaimana tingkat akurasi Fuzzy Inference System (FIS) Mamdani dalam mendeteksi risiko stunting?
2. Bagaimana efektivitas Sistem Pakar berbasis Forward Chaining dalam menyajikan diagnosa dan rekomendasi klinis?
3. Apakah optimasi hyperparameter pada algoritma XGBoost dapat mengungguli sistem berbasis aturan konvensional?

1.3 Tujuan

1. Mengimplementasikan metode FIS Mamdani, Sistem Pakar, dan XGBoost untuk klasifikasi risiko stunting.
2. Menganalisis akurasi, sensitivitas (recall), dan presisi dari masing-masing metode.
3. Menyimpulkan metode terbaik untuk diintegrasikan ke sistem pemantauan posyandu.

BAB II: METODOLOGI DAN PERSIAPAN DATA

2.1 Deskripsi Dataset

Eksperimen ini menggunakan dua dataset berbeda untuk memfasilitasi kebutuhan masing-masing metode:

- Dataset A (FIS & Sistem Pakar): Berisi 200 rekam medis balita dengan fitur utama: Umur (bulan), Berat Badan (kg), Tinggi Badan (cm), LILA (cm), dan ASI Eksklusif.
- Dataset B (XGBoost): Berisi 200 data berlabel untuk proses training dan testing machine learning.

[Silakan sisipkan Screenshot representasi tabel Dataset A & B di sini]

2.2 Estimasi Standar Antropometri (Z-Score)

Sebelum data diproses oleh FIS dan Sistem Pakar, nilai antropometri (BB, TB, Umur) dikonversi terlebih dahulu menjadi indeks Z-Score BB/U (Berat Badan menurut Umur) dan

TB/U (Tinggi Badan menurut Umur) dengan formula matematika estimasi deviasi terhadap nilai median populasi standar.

BAB III: IMPLEMENTASI SISTEM CERDAS

3.1 Implementasi Fuzzy Inference System (FIS) Mamdani

Sistem ini memetakan variabel input kontinu Z-Score BB/U (zbb) dan TB/U (ztb) ke dalam 3 himpunan fuzzy (rendah, normal, tinggi) menggunakan fungsi keanggotaan trapezoid dan segitiga. Output berupa skor risiko (0-100) yang terbagi menjadi Rendah, Sedang, dan Tinggi.

[Silakan sisipkan Gambar Grafik Membership Function Z-Score BB/U, TB/U, dan Output di sini]

[Silakan sisipkan Gambar Grafik Distribusi Skor Risiko FIS Mamdani di sini]

3.2 Implementasi Sistem Pakar Forward Chaining

Sistem Pakar mengadopsi 9 aturan kepakaran (R1 s.d R9). Berikut adalah pembuktian jalannya mesin inferensi menggunakan representasi data pada pasien B02 (Siti Rahayu):

DATA PASIEN B02 (Siti Rahayu):
- Umur: 36 bulan
- Berat Badan: 11.8 kg
- Tinggi Badan: 88.0 cm
- LILA: 12.1 cm
- Z-Score BB/U: -1.11
- Z-Score TB/U: -1.39
- Skor Risiko FIS: 53.35

PROSES INFERENSI (FORWARD CHAINING):
- Menilai kondisi LILA < 12.5 cm DAN Risiko FIS >= 40: Aturan R5 MATCH -> FIRED (Sistem menyimpulkan sementara status GIZI KURANG).
- Menilai kondisi Risiko FIS >= 40: Aturan R6 MATCH -> FIRED.
- Hasil Akhir Diagnosa: GIZI KURANG.
- Rekomendasi: Lakukan pemeriksaan status gizi dan konsultasi tenaga kesehatan.

3.3 Klasifikasi Menggunakan XGBoost Classifier

Algoritma XGBoost dilatih menggunakan Dataset B (80% training, 20% testing). Optimasi hyperparameter dilakukan menggunakan Stratified 5-Fold Cross Validation. Hyperparameter terbaik yang diperoleh adalah:
- colsample_bytree: 0.9
- learning_rate: 0.05
- max_depth: 3
- n_estimators: 150
- subsample: 0.8

Kinerja Model Hasil Testing:
- Akurasi: 85.0%
- Presisi: 84.62%
- Recall (Sensitivitas): 73.33%
- F1-Score: 78.57%
- ROC-AUC: 85.33%

[Silakan sisipkan Gambar Confusion Matrix & Feature Importance XGBoost di sini]

BAB IV: ANALISIS PERBANDINGAN DAN PEMBAHASAN

4.1 Hasil Perbandingan Akhir

Berikut adalah tabel komparasi kinerja dari ketiga model cerdas yang diuji menggunakan 40 data uji independen:

Metode	Accuracy (%)	Precision (%)	Recall (%)	F1-Score (%)	ROC-AUC (%)
FIS Mamdani	40.0	43.48	66.67	52.63	40.40
Sistem Pakar	37.5	41.67	66.67	51.28	43.33
XGBoost (Tuned)	85.0	84.62	73.33	78.57	85.33

4.2 Analisis Kritis Performa

Berdasarkan tabel di atas dan visualisasi akurasi, dapat ditarik beberapa poin analisis kritis:
1. XGBoost menghasilkan performa superior (Akurasi 85%) karena algoritma ini mampu melatih bobot relasi non-linear secara optimal langsung dari data aktual (Dataset B).
2. FIS Mamdani (40%) dan Sistem Pakar (37.5%) menunjukkan performa rendah pada data pengujian. Hal ini disebabkan karena kedua metode tersebut mengandalkan batasan aturan kaku (rule-based) buatan manusia. Batasan matematis bernilai biner/tajam kurang adaptif terhadap data riil yang bervariasi luas.
3. Namun keunggulan Sistem Pakar dan FIS terletak pada kemampuan interpretasi pengambilan keputusannya yang transparan (Explainable AI), seperti yang ditunjukkan pada runtunan logika kasus Siti Rahayu.

BAB V: KESIMPULAN DAN SARAN

5.1 Kesimpulan

Penelitian ini berhasil membuktikan bahwa model prediktif berbasis machine learning (XGBoost) memberikan hasil klasifikasi risiko stunting yang jauh lebih handal dan akurat (85.0%) dibandingkan model manual berbasis aturan seperti FIS Mamdani dan Sistem Pakar Forward Chaining.

5.2 Saran

Disarankan untuk mengombinasikan kekuatan pembelajaran XGBoost dengan transparansi logika Fuzzy (seperti menggunakan metode Adaptive Neuro-Fuzzy Inference System - ANFIS) guna mendapatkan sistem cerdas yang akurat sekaligus mudah dipahami oleh praktisi medis.

Soal 2

Knowledge Base (Aturan IF-THEN)

- **R1:** IF berat_badan_kurang = YA AND usia_di_bawah_24_bulan = YA =>THEN risiko_stunting_dini = YA
- **R2:** IF risiko_stunting_dini = YA AND asi_eksklusif_tidak = YA => THEN stunting_berpotensi_parah = YA
- **R3:** IF tinggi_badan_pendek = YA AND berat_badan_kurang = YA => THEN gizi_buruk = YA
- **R4:** IF gizi_buruk = YA OR stunting_berpotensi_parah = YA => THEN rujuk_puskesmas = YA
- **R5:** IF rujuk_puskesmas = YA AND orang_tua_menolak = TIDAK => THEN jadwalkan_pemantauan_intensif = YA

Kasus Pasien: Hana (20 bulan)

- berat_badan_kurang = **YA**
- usia_di_bawah_24_bulan = **YA**
- asi_eksklusif_tidak = **YA**
- tinggi_badan_pendek = **TIDAK**
- orang_tua_menolak = **TIDAK**

A. Tracing Forward Chaining

Iterasi	**Working Memory (WM)**	**Rules yang Match**	Rule yang Fired	Fakta Baru ke WM
Awal	berat_badan_kurang=YA, usia_di_bawah_24_bulan=YA, asi_eksklusif_tidak=YA, tinggi_badan_pendek=TIDAK, orang_tua_menolak=TIDAK	R1	-	-
1	(Sama seperti awal + fakta baru)	R1	R1	risiko_stunting_dini = YA

2	berat_badan_kurang=YA, usia_di_bawah_24_bulan=YA, asi_eksklusif_tidak=YA, tinggi_badan_pendek=TIDAK, orang_tua_menolak=TIDAK, risiko_stunting_dini=YA	R2	R2	stunting_berpotensi_parah = YA
3	(ditambah stunting_berpotensi_parah=YA)	R4	R4	rujuk_puskesmas = YA
4	(ditambah rujuk_puskesmas=YA)	R5	R5	jadwalkan_pemantauan_intensif = YA

Kesimpulan Akhir Forward Chaining untuk Hana:

Berdasarkan hasil penelusuran Forward Chaining, sistem berhasil mencapai kesimpulan akhir bahwa balita Hana memerlukan tindakan jadwalkan_pemantauan_intensif = YA (serta memenuhi status risiko_stunting_dini, stunting_berpotensi_parah, dan rujuk_puskesmas = YA).

b. Tracing Backward Chaining

(i) Pohon Pembuktian Backward Chaining (Goal Tree)

```
GOAL: jadwalkan_pemantauan_intensif = YA
└── Cari rule yang mendukung → R5
    ├── Sub-goal 1: rujuk_puskesmas = YA
    │   └── Cari rule yang mendukung → R4
    │       ├── Sub-goal 1.1: gizi_buruk = YA
    │       │   └── Cari rule pendukung → R3
    │       │       ├── Sub-goal 1.1.1: tinggi_badan_pendek = YA -> (Fakta: TIDAK - Gagal)
    │       │       └── Sub-goal 1.1.2: berat_badan_kurang = YA -> (Fakta: YA - Sukses)
    │       │      [Hasil R3: Gagal / FALSE]
    │       │   OR (Cabang Alternatif R4)
    │       └── Sub-goal 1.2: stunting_berpotensi_parah = YA
    │           └── Cari rule pendukung → R2
    │               ├── Sub-goal 1.2.1: risiko_stunting_dini = YA
    │               │   └── Cari rule pendukung → R1
    │               │       ├── Sub-goal 1.2.1.1: berat_badan_kurang = YA -> (Fakta: YA)
    │               │       └── Sub-goal 1.2.1.2: usia_di_bawah_24_bulan = YA -> (Fakta: YA)
    │               │      [Hasil R1: Sukses -> risiko_stunting_dini = YA]
    │               └── Sub-goal 1.2.2: asi_eksklusif_tidak = YA -> (Fakta: YA - Sukses)
    │              [Hasil R2: Sukses -> stunting_berpotensi_parah = YA]
    │          [Hasil R4: Sukses karena Sub-goal 1.2 terpenuhi -> rujuk_puskesmas = YA]
    └── Sub-goal 2: orang_tua_menolak = TIDAK -> (Fakta: YA / Sesuai - Sukses)
[Hasil R5: Sukses -> Goal "jadwalkan_pemantauan_intensif = YA" tercapai]
```

(ii) Perbandingan Backward Chaining dengan Forward Chaining

- Kesimpulan: Ya, kedua metode mencapai kesimpulan yang sama yaitu `jadwalkan_pemantauan_intensif = YA`.
- Perbedaan Efisiensi:
  - Forward Chaining bekerja dari data awal menuju ke tujuan (bottom-up), mengevaluasi rule secara berurutan sesuai fakta yang tersedia (mengevaluasi R1, R2, R4, dan R5 secara linier tanpa mengevaluasi R3 yang tidak relevan).
  - Backward Chaining bekerja dari goal/tujuan mundur ke belakang (top-down). Metode ini mencoba membuktikan sub-goal satu per satu. Pada kasus ini, ketika

mengevaluasi R3 (melalui cabang `gizi_buruk`), sistem sempat mengecek `tinggi_badan_pendek` dan mendapatinya bernilai TIDAK (sehingga jalur R3 gagal), sebelum akhirnya beralih memeriksa jalur `stunting_berpotensi_parah` melalui R2 dan R1 yang bernilai YA.

- Dari segi jumlah rule yang diuji/dievaluasi secara spesifik untuk mencapai goal, Forward Chaining cenderung lebih langsung pada kasus ini karena langsung mengeksekusi rule yang aktif dari fakta dasar, sementara Backward Chaining melakukan eksplorasi cabang percabangan alternatif (`gizi_buruk` vs `stunting_berpotensi_parah`) saat menelusuri premis R4.

SOAL KE 3

Aspek A — Kondisi masalah yang cocok untuk Sistem Pakar (minimal 3 karakteristik)

Sistem Pakar (*Expert System*) berbasis aturan terstruktur (*rule-based*) sangat cocok diterapkan pada kondisi masalah dengan karakteristik sebagai berikut:

1. **Keterbatasan Data Historis (Cold Start Problem):** Sistem Pakar tidak bergantung pada ketersediaan dataset berukuran besar untuk dilatih. Ketika data historis tidak ada atau sangat minimal, pengetahuan ditransformasikannya secara langsung dari kepakaran pakar manusia ke dalam basis pengetahuan (*knowledge base*) menggunakan logika *IF-THEN*.
2. **Kebutuhan Transparansi dan Interpretabilitas Mutlak (White-box Model):** Pada domain sensitif seperti hukum atau medis, setiap keputusan harus dapat dijelaskan jejak deduksinya (*explainability*). Sistem Pakar menyediakan mekanisme *inference engine* berbasis *forward* atau *backward chaining* yang memvisualisasikan alur penalaran secara gamblang.
3. **Domain Berbasis Regulasi dan Aturan Manusia yang Baku:** Masalah yang memiliki aturan deterministic, Standar Operasional Prosedur (SOP), atau legalitas tertulis yang ketat lebih tepat ditangani Sistem Pakar. Logika domain kepakaran dapat direpresentasikan dengan tepat tanpa risiko deviasi statistik.

Aspek B — Kondisi masalah yang cocok untuk XGBoost (minimal 3 karakteristik)

XGBoost (*eXtreme Gradient Boosting*) merupakan algoritma *machine learning* berbasis *tree-boosting* ensemble yang unggul pada kondisi masalah berikut:

1. **Ketersediaan Data Tabular Berukuran Besar dan Kompleks:** XGBoost dirancang untuk mengolah dataset terstruktur yang sangat besar dengan pola non-linear komputasional tinggi yang sulit dirumuskan manual oleh manusia.
2. **Toleransi terhadap *Noise* dan *Missing Values*:** XGBoost memiliki algoritma bawaan (*sparsity-aware split finding*) yang dapat menangani data hilang (*missing values*) serta outlier secara efektif tanpa mengurangi akurasi secara drastis.
3. **Fokus Utama pada Presisi Prediksi dibanding Formulasi Aturan:** Ketika tujuan utama sistem adalah memaksimalkan matriks performa (seperti *Accuracy*, *F1-Score*, atau *ROC-AUC*) pada fenomena dinamis, XGBoost mampu menemukan asosiasi tersembunyi (*hidden patterns*) secara otomatis melalui optimasi gradien.

Aspek C — Kasus nyata Indonesia + analisis mendalam

1. Deskripsi Masalah:

Sistem Penapisan/Triase Pertolongan Pertama dan Diagnosa Penyakit Endemis Tanaman Padi di tingkat Pos Penyuluhan Pertanian (Posluhdes) daerah terpencil Indonesia.

2. Mengapa Sistem Pakar Lebih Tepat:

Di wilayah pelosok Indonesia, dokumentasi digital penyakit tanaman historis sering kali sangat minim atau tidak terstruktur. Namun, kepakaran agronom dari dinas pertanian/pakar HPT (Hama dan Penyakit Tanaman) mengenai gejala klinis penyakit (seperti Hama Wereng Batang Cokelat atau Penyakit Tungro) sudah terstandardisasi secara ilmiah. Dengan Sistem Pakar berbasis metode *Certainty Factor* atau *Forward Chaining*, pengetahuan penyuluhan pertanian dapat dialihkan ke aplikasi offline/ringan. Penyuluh di lapangan mendapatkan kepastian deduktif yang jelas mengenai alasan suatu diagnosis diambil berdasarkan SOP klinis pertanian yang berlaku.

3. Kelemahan jika XGBoost Dipaksakan Digunakan:

- **Ketidaktersediaan Data Training:** XGBoost memerlukan data riwayat sampel penyakit dalam jumlah puluhan ribu baris yang terlabel dengan presisi tinggi. Tanpa data ini, model akan mengalami *overfitting* berat.
- **Risiko *Black-Box*:** Petani dan penyuluh sulit mempercayai luaran XGBoost jika sistem tidak memberikan penjelasan rantai logika medis/pertanian di balik rekomendasi yang diberikan.

Aspek D — Skenario integrasi Sistem Pakar + XGBoost

Kedua pendekatan ini dapat diintegrasikan dalam arsitektur **Hybrid Intelligent System** pada kasus **Sistem Persetujuan Kredit Keuangan (Credit Scoring & Compliance)** di Industri Fintech/Perbankan Indonesia.

Skenario Kerja Sama dan Alur Data (Output ke Input):

1. **Tahap 1 (XGBoost sebagai Feature Generator / Initial Scorer):** Data riwayat transaksi, profil demografi, dan *behavioral log* nasabah dimasukkan ke dalam model XGBoost. XGBoost memprediksi *Probability of Default* (PD) dan menghasilkan nilai skor risiko (*Risk Score*: 0–100).
2. **Tahap 2 (Sistem Pakar sebagai Decision & Compliance Engine):** Output *Risk Score* dari XGBoost beserta fitur penting lainnya diteruskan sebagai **INPUT** ke dalam Sistem Pakar berbasis aturan.
3. **Eksekusi Penalaran:** Sistem Pakar mengevaluasi input tersebut menggunakan aturan regulator (OJK/BI), seperti:
   - `IF Risk_Score < 30 AND Pendapatan_Tetap == TRUE AND Status_Daftar_Hitam == FALSE THEN Approve_Kredit`
   - `IF Status_Daftar_Hitam == TRUE THEN Reject_Kredit (Bypass output XGBoost)`

Dengan integrasi ini, kecerdasan statistik XGBoost dalam mengenali pola risiko nasabah dipadukan dengan kepastian hukum/regulasi dari Sistem Pakar.

Daftar Referensi (minimal 2, APA style)

- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. https://doi.org/10.1145/2939672.2939785
- Giarratano, J. C., & Riley, G. D. (2005). *Expert systems: Principles and programming* (4th ed.). Thomson Course Technology.
- Russell, S., & Norvig, P. (2020). *Artificial intelligence: A modern approach* (4th ed.). Pearson.